



**Tecnológico
de Monterrey**

Módulo 2 Análisis y Reporte sobre el desempeño del modelo
Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Alejandro Vázquez de la Cruz

16 de septiembre 2026

Árbol de decisión (manual) sobre Telco Customer Churn

Dataset y separación de datos


Se reutiliza el árbol de decisión implementado manualmente (decision_tree.py, entrega 1) sobre el mismo dataset Telco Customer Churn (7,043 clientes, 20 features tras limpieza). A continuación, la distribución de los datos:

Conjunto	Filas	Proporción	Uso
Train	4,225	60%	Entrenar cada configuración del árbol
Validation	1,409	20%	Elegir hiperparámetros (se consulta repetidamente)
Test	1,409	20%	Evaluación final, se toca una sola vez

La separación estratificada por Churn se aplicó en dos cortes sucesivos: primero 60/40 (train vs. resto), y el 40% restante se dividió a la mitad para obtener validation y test. El test solo se usa al final, con la configuración de hiperparámetros ya decidida — así la medición final no está sesgada por haber sido usada también para elegir el modelo.

Curva de complejidad: diagnóstico de bias y varianza

Se entrenó el árbol con profundidades crecientes (max_depth de 1 a 15), midiendo accuracy en train y en validation en cada una. Por costo computacional (la columna TotalCharges tiene ~6,500 valores únicos, lo que hace cada entrenamiento sobre el train completo lento), esta curva exploratoria se generó sobre una submuestra aleatoria de 1,000 filas del train.



La curva muestra el patrón clásico de bias-varianza: en max_depth=1 ambas curvas son bajas y casi idénticas (bias alto, underfitting). El mejor balance ocurre alrededor de max_depth=3 (brecha de solo 0.008). A partir de ahí, mientras el train sigue subiendo (de 0.818 en depth=5 a 0.874 en depth=15), el validation cae de forma sostenida (de

0.773 a 0.744), la brecha crece de 0.045 a 0.130, la firma clásica de varianza creciente y overfitting progresivo.

Criterio de diagnóstico utilizado

Para no depender de una lectura subjetiva de los números, se definió un criterio explícito:

- Bias: alto si accuracy en train < 0.75 ; bajo si > 0.85 ; medio en el resto.
- Varianza: alta si la brecha train-validation > 0.08 ; baja si < 0.03 ; media en el resto.
- Nivel de ajuste: bias alto $\Rightarrow$ underfitting; varianza alta $\Rightarrow$ overfitting; en cualquier otro caso $\Rightarrow$ buen ajuste (fit).

Diagnóstico del modelo original (max_depth=5, min_samples_split=20)

Esta fue la configuración usada en la entrega anterior. Evaluada sobre el train completo:

Métrica	Valor
Accuracy train	0.805
Accuracy validation	0.789
Accuracy test	0.784
Brecha train-validation	0.017

Diagnóstico: Bias = medio, Varianza = baja, Ajuste = buen ajuste (fit).

Resultado interesante en contraste con la curva anterior: en la submuestra de 1,000 filas, max_depth=5 ya mostraba señales de sobreajuste (brecha=0.045); con el train completo (4,225 filas), la brecha para ese mismo max_depth baja a 0.017. Esto ilustra que la varianza no depende solo de la complejidad del modelo, también depende de cuántos datos hay disponibles: el mismo árbol es "más complejo relativo a los datos" cuando se entrena con 1,000 filas que cuando se entrena con 4,225.

Ajuste de hiperparámetros (regularización)


Se realizó una búsqueda en dos etapas: exploratoria rápida sobre la submuestra para ubicar la región prometedora, y un grid fino sobre el train completo para confirmar el resultado con datos reales. min_samples_split actúa como segunda palanca de regularización: valores más altos evitan que el árbol cree hojas basadas en muy pocos ejemplos (ruido), reduciendo varianza a costa de un poco de bias.

max_depth	min_samples_split	Acc. train	Acc. validation	Brecha
5	50	0.805	0.789	0.017
6	100	0.813	0.792	0.021
7	150	0.815	0.792	0.023
7	200	0.811	0.795	0.016
8	200	0.811	0.795	0.016

Mejor configuración encontrada: max_depth=8, min_samples_split=200 (empatada con max_depth=7, min_samples_split=200 en accuracy de validation).

Comparación final: modelo original vs. modelo ajustado

El modelo ajustado se evaluó una sola vez sobre el conjunto de test, después de haber elegido la configuración usando solo train y validation:



	Original	Ajustado	Diagnóstico
Accuracy train	0.805	0.811	
Accuracy validation	0.789	0.795	
Accuracy test	0.784	0.786	
Brecha train-val	0.017	0.016	
Bias / Varianza / Ajuste	medio / bajo / fit	medio / bajo / fit	sin cambio de categoría

Análisis y conclusión

El ajuste de hiperparámetros logró una mejora consistente en los tres conjuntos (train +0.6 pp, validation +0.6 pp, test +0.2 pp), incluyendo el test (nunca antes visto durante el proceso de ajuste), lo que confirma que la mejora generaliza y no es un artefacto de haber consultado el validation set varias veces.

El diagnóstico cualitativo (bias medio, varianza baja, buen ajuste) no cambió de categoría entre el modelo original y el ajustado. Esto es en sí mismo un hallazgo relevante: el modelo original ya estaba razonablemente bien balanceado, sin un problema evidente de bias o varianza que "arreglar" la mejora obtenida es real pero incremental, no una corrección de un defecto grave.

El árbol de decisión, sobre este dataset y con este espacio de hiperparámetros, converge a un techo de desempeño alrededor de 78-81% de accuracy. Futuras mejoras de desempeño probablemente requerirían más que ajustar `max_depth` y `min_samples_split` por ejemplo, un modelo de mayor capacidad como Random Forest.